Supervised Learning & Model Engineering

Prédire le revenu pour cibler une offre bancaire premium

Rapport du projet

Jeu de données utilisé : Option 1 - Adult / Census Income

`fetch_openml(name="adult", version=2)`

CAILLAUD Jérémy - RAJHI Yanis - VAN ZUYLEN Hugo

Albert School - Enseignante : Ilana Sebag

Octobre 2026

Dépôt GitHub : github.com/CLDprog/Supervised-Learning-Census-Income-

Sommaire

1. Introduction et cadrage du problème 3
1.1 Problème et cas d'usage 3
1.2 Métriques et règle de décision 3
1.3 Découpage des données 3
2. Données et audit de fuite 4
2.1 Analyse exploratoire 4
2.2 Audit de fuite et variables retirées 4
3. Ingénierie des variables et Pipeline 5
3.1 Valeurs manquantes 5
3.2 Encodage et modalités rares 5
3.3 Trois nouvelles variables 5
3.4 Mise à l'échelle 6
3.5 Un Pipeline unique 6
4. Gestion du déséquilibre des classes 6
5. Progression de modélisation, réglage et suivi 7
5.1 Trois modèles, une progression 7
5.2 Réglage des hyperparamètres avec Optuna 7
5.3 Suivi des expériences avec MLflow 8
6. Explicabilité et diagnostic du modèle final 9
6.1 Importance globale (SHAP) 9
6.2 Explications locales 10
6.3 Diagnostic par segment 10
7. Diagnostics de calibration 11
8. Audit d'équité et de biais 12
8.1 Définition d'équité et audit 12
8.2 Mitigation et comparaison sur le test 12
8.3 Limites 13
9. Évaluation finale, limites et conclusion 13
Annexes 14
A. Dictionnaire des variables 14
B. Analyse exploratoire complémentaire 15
C. Réglage des hyperparamètres 16
D. Résultats détaillés 17
E. Explicabilité complémentaire 18
F. Glossaire des métriques et des définitions d'équité 19
G. Organisation du code, reproduction et API 20
H. Déclaration d'utilisation d'un assistant de code IA 20
I. Déclaration de contribution 21

1. Introduction et cadrage du problème

Ce projet construit une preuve de concept complète de machine learning supervisé sur le jeu de données Adult / Census Income (recensement américain de 1994) : de l'analyse exploratoire jusqu'à une API de prédiction. Avant tout modèle, nous avons fixé le cadre du problème, car c'est lui qui justifie la métrique, le seuil de décision, les variables autorisées et la définition d'équité.

1.1 Problème et cas d'usage

La tâche est une **classification binaire** : estimer la probabilité P(Y = 1 | X) qu'une personne gagne plus de 50 K$ par an. La classe positive `>50K` représente **23,9 %** des personnes.

Nous l'avons inscrite dans un cas d'usage : une **banque veut proposer une offre premium à ses clients existants** qui gagnent probablement plus de 50 K$. Le modèle classe les clients par probabilité. L'équipe marketing décide qui contacter à partir d'un seuil. Le modèle ne décide donc pas seul. Les deux erreurs ont des coûts différents : un **faux négatif** (un client `>50K` non contacté) fait perdre une vente, alors qu'un **faux positif** (un client `<=50K` contacté) ne coûte qu'une sollicitation inutile. Nous privilégions donc le **rappel**, sans laisser la précision s'effondrer.

1.2 Métriques et règle de décision

Un modèle qui répond toujours `<=50K` atteint déjà **76,1 % d'accuracy**, avec un rappel nul : l'accuracy ne peut pas être notre métrique. Nous retenons la **PR-AUC** (*average precision*) comme métrique principale : elle ne dépend pas du seuil, se concentre sur la classe positive et pénalise directement les faux positifs dans la précision. Son niveau de hasard est la part de positifs, **0,239**. Le déséquilibre étant modéré (24 %), la ROC-AUC n'est pas trompeuse, nous la rapportons en complément, avec la précision, le rappel, le F1 et la matrice de confusion. Le score de Brier et l'ECE servent à juger les probabilités (partie 7).

Règle de décision : le seuil n'est pas fixé à 0,5. Nous retenons **le seuil le plus élevé qui garde un rappel d'au moins 80 %**, choisi sur la validation : nous acceptons de rater au plus un client `>50K` sur cinq, avec la meilleure précision possible. Changer le seuil ne modifie ni le modèle ni sa PR-AUC : la PR-AUC sert à comparer les modèles, le seuil à décider.

1.3 Découpage des données

Après suppression de 52 doublons stricts (identiques jusqu'au poids de sondage), le jeu compte 48 790 lignes. Nous le découpons en **70 / 15 / 15**, de façon **stratifiée** sur la cible et avec une graine fixe :

- **train** (34 152 lignes) : apprentissage des modèles et réglage des hyperparamètres par Optuna, en validation croisée à 5 plis ;
- **validation** (7 319 lignes) : comparaison des modèles réglés, choix du seuil, calibration et correction d'équité ;
- **test** (7 319 lignes, dont 1 752 positifs) : mesure de la performance finale, **une seule fois**, quand tous les choix sont figés.

Ce découpage est honnête : les doublons sont supprimés avant, les données n'ont ni date ni identifiant (un tirage aléatoire est légitime), et le test n'influence aucun choix. Le meilleur score de validation croisée d'Optuna étant optimiste (les mêmes plis servent à choisir et à évaluer), les modèles réglés sont comparés sur la validation. Nous n'avons pas utilisé de validation croisée imbriquée : elle multiplie le coût du réglage par le nombre de plis externes, et un test de 7 319 lignes gardé intact suffit à une estimation fiable (stratégie « réglage par validation croisée + jeu de test »). Limite : la validation servant à plusieurs décisions, ses scores sont un peu optimistes, seul le score du test est présenté comme la performance finale.

2. Données et audit de fuite

2.1 Analyse exploratoire

Le jeu de données décrit chaque personne par 14 variables (6 numériques, 8 catégorielles). Les constats de l'EDA qui ont orienté le prétraitement sont résumés ci-dessous (dictionnaire des variables en annexe A, analyses complémentaires en annexe B).

Tableau 1 - Principaux constats de l'analyse exploratoire

Constat	Conséquence
52 lignes strictement identiques	Supprimées avant le découpage
Manquants : `workclass` et `occupation` (5,7 %, mêmes lignes), `native-country` (1,8 %)	Traitement dans le Pipeline (partie 3.1)
`education` et `education-num` portent la même information	On garde `education-num`, qui conserve l'ordre
`capital-gain` : 91,7 % de zéros, plafond à 99 999 (244 lignes, toutes `>50K`)	Lignes conservées ; transformation logarithmique
Modalités rares (`Never-worked` : 10, `Armed-Forces` : 15) ; 41 pays dont 91 % de `United-States`	Regroupement des modalités rares (partie 3.2)
Cible déséquilibrée : 23,9 % de `>50K`	PR-AUC, découpage stratifié, partie 4

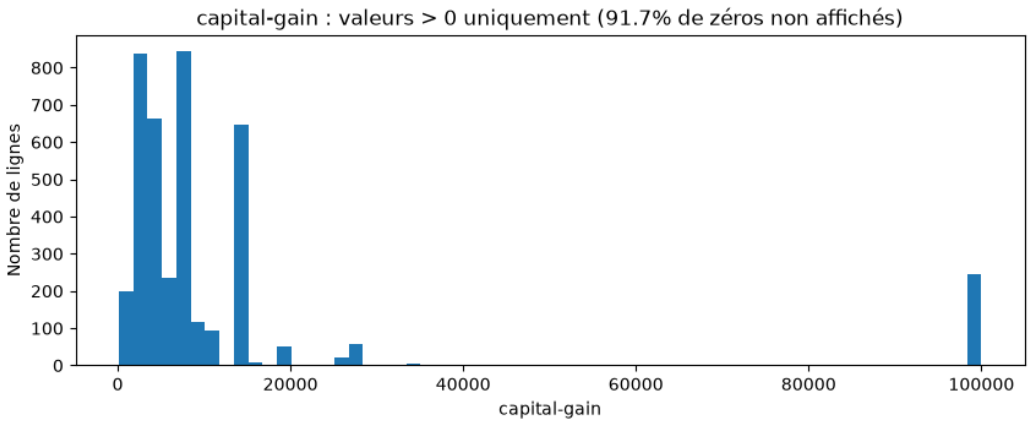


Figure 1 - Distribution de capital-gain hors zéros : la barre isolée à droite correspond au plafond de saisie de 99 999.

2.2 Audit de fuite et variables retirées

Une fuite de données survient quand le modèle utilise une information qu'il n'aurait pas au moment réel de la prédiction. Chaque variable doit passer un test : **pourrait-on vraiment connaître cette valeur au moment où l'on prédit ?** Dans notre scénario, ce moment est le lancement d'une campagne : la banque connaît le profil déclaré par le client et son activité financière de l'année.

- **`capital-gain` et `capital-loss`** sont mesurés la même année que le revenu et très liés à la cible : 8,3 % des personnes ont un gain en capital, dont 61,7 % sont `>50K` (contre 23,9 % en moyenne). Ce n'est pas leur pouvoir prédictif qui pose question, mais leur disponibilité. Pour des **clients existants**, la banque connaît leurs plus-values et moins-values : nous les **gardons**. Pour de nouveaux prospects, ce serait une fuite.
- **`fnlwgt`** est un poids de sondage du recensement, pas une caractéristique de la personne : il n'existe pas pour un client, et seul il ne prédit rien (ROC-AUC de 0,496, contre 0,68 à 0,72 pour age, `education-num` et `hours-per-week`). Il est **retiré**. Il aurait pu servir de poids d'échantillonnage pour représenter la population américaine, mais notre population cible est celle des clients de la banque.

- **`sex` et `race`** sont des attributs protégés : cibler une offre selon le sexe ou l'origine serait discriminatoire. Ils sont **retirés des variables du modèle** et conservés pour l'audit d'équité et les diagnostics.

Les autres risques sont maîtrisés ou signalés : aucune fuite temporelle (toutes les variables viennent de la même enquête) ; pas de fuite de prétraitement grâce au Pipeline ; en revanche, faute d'identifiant de ménage, deux conjoints d'un même foyer peuvent se retrouver l'un dans le train, l'autre dans le test (limite non contrôlable).

3. Ingénierie des variables et Pipeline

Toutes les analyses qui ont guidé ces choix ont été faites **sur le train uniquement** ; les règles apprises sur le train sont ensuite appliquées à l'identique à la validation, au test et à l'API, grâce au Pipeline.

3.1 Valeurs manquantes

Sur le train, les personnes dont `workclass` ou `occupation` manque ne sont que **9,4 %** en `>50K`, contre **24,8 %** quand la valeur est renseignée : **le manque est informatif** (sans emploi, retraite, emploi précaire). Imputer par la modalité la plus fréquente (`Private`) effacerait cette information. Nous créons donc une modalité **`Unknown`** (`SimpleImputer(strategy="constant")`), appliquée aussi à `native-country` par cohérence. Les numériques n'ont aucun manquant, mais une imputation par la médiane du train est prévue par sécurité pour l'API.

3.2 Encodage et modalités rares

Les catégorielles sont encodées en **one-hot** : une colonne 0/1 par modalité. Contrairement à un encodage par numéros, il n'invente pas d'ordre entre modalités (indispensable pour la régression logistique), contrairement au *target encoding*, il n'utilise pas la cible, donc aucun risque de fuite.

Une modalité vue dans moins de **50 lignes du train** est regroupée dans une colonne « infrequent » (`OneHotEncoder(min_frequency=50, handle_unknown="infrequent_if_exist")`). Ce seuil se justifie par la précision d'un taux : la marge d'erreur à 95 % sur la part de `>50K` d'une modalité de *n* personnes vaut environ ±26 points pour 10 personnes, **±12 points pour 50**, ±8 points pour 100. Sous 50 lignes, une modalité compte moins d'une dizaine de positifs attendus.

Sont regroupés : 2 modalités de `workclass`, 1 de `marital-status`, 1 de `occupation` et 20 pays sur 42 (500 lignes au total). Le même mécanisme absorbe les modalités jamais vues (un pays absent des données envoyé à l'API), au lieu de faire échouer l'encodage. On obtient 59 colonnes one-hot.

3.3 Trois nouvelles variables

- **`age_carre`** : la part de `>50K` suit une courbe en cloche selon l'âge (2 % avant 25 ans, 39 % entre 46 et 55 ans, 20 % après 65 ans). Une régression logistique ne peut tracer qu'une pente ; l'âge au carré lui permet de tracer une parabole, comme dans l'équation de Mincer en économie du travail. En validation croisée, la PR-AUC d'une logistique passe de **0,319** (âge seul) à **0,369** (âge et âge au carré).
- **`a_des_placements`** (1 si gain ou perte en capital) : de façon contre-intuitive, les personnes ayant réalisé une **perte** sont 50,2 % en `>50K`, presque autant que celles ayant réalisé un gain (61,7 %), contre 18,9 % sans placement. Ce qui compte est le fait d'avoir un portefeuille, donc un patrimoine. Cette variable réunit les deux colonnes en un seul signal (13,1 % des personnes, dont 57,5 % `>50K`).
- **`log_capital_gain` et `log_capital_loss`** (log(1 + x)) : les zéros sont de vrais zéros (aucun `NaN`), le problème est l'asymétrie. Le logarithme écrase les montants extrêmes sans changer l'ordre ni les zéros : l'asymétrie de `capital-gain` tombe de 11,7 à 3,1. Pour `capital-loss`, elle bouge peu (4,5 à 4,3),

car elle vient surtout de la masse de zéros, mais l'échelle passe de 0-4 356 à 0-8,4. Ces colonnes remplacent les montants bruts.

Ces variables, calculées ligne par ligne, ne présentent aucun risque de fuite ; elles aident surtout la régression logistique, les arbres trouvant seuls seuils et interactions.

3.4 Mise à l'échelle

Les numériques sont **standardisées** (moyenne 0, écart-type 1, appris sur le train). Sans cela, la régularisation de la régression logistique serait injuste : elle pénalise les coefficients selon leur taille, qui dépend de l'unité (`age_carre` va jusqu'à 8 100, `education-num` jusqu'à 16). Les arbres n'en ont pas besoin, mais un prétraitement commun permet de comparer les modèles à égalité. Sur la validation, les moyennes standardisées valent entre −0,02 et 0, et non exactement 0 : la validation est bien transformée avec les paramètres du train.

3.5 Un Pipeline unique

Tout est regroupé dans un **Pipeline** scikit-learn : un `FunctionTransformer` crée les nouvelles variables, puis un `ColumnTransformer` envoie les catégorielles vers l'imputation `Unknown` et le one-hot, les numériques vers l'imputation par la médiane et la standardisation (66 colonnes au total), et le modèle conclut. Les colonnes non listées (`fnlwgt`, `education`, `sex`, `race`, montants bruts) sont ignorées. Ce regroupement garantit l'absence de fuite en validation croisée (le prétraitement est réappris dans chaque pli), la reproductibilité et le déploiement : le Pipeline sauvegardé avec `joblib` prédit directement sur les données brutes d'un client. En développant l'API, nous avons détecté qu'une valeur `None` n'était pas reconnue comme manquante par `SimpleImputer`. La création de variables convertit désormais tout manquant en `NaN`.

4. Gestion du déséquilibre des classes

Sans remède, une régression logistique avec ce prétraitement **classe bien** les personnes (PR-AUC de 0,788, ROC-AUC de 0,916), mais au seuil de 0,5 elle ne trouve que **1 046 des 1 752 `>50K`** de la validation : un rappel de 59,7 %, loin des 80 % visés. Entraîné sur 76 % de `<=50K`, le modèle donne à beaucoup de vrais `>50K` une probabilité de 0,3 ou 0,4 : ils sont bien classés, mais pas assez haut pour franchir 0,5.

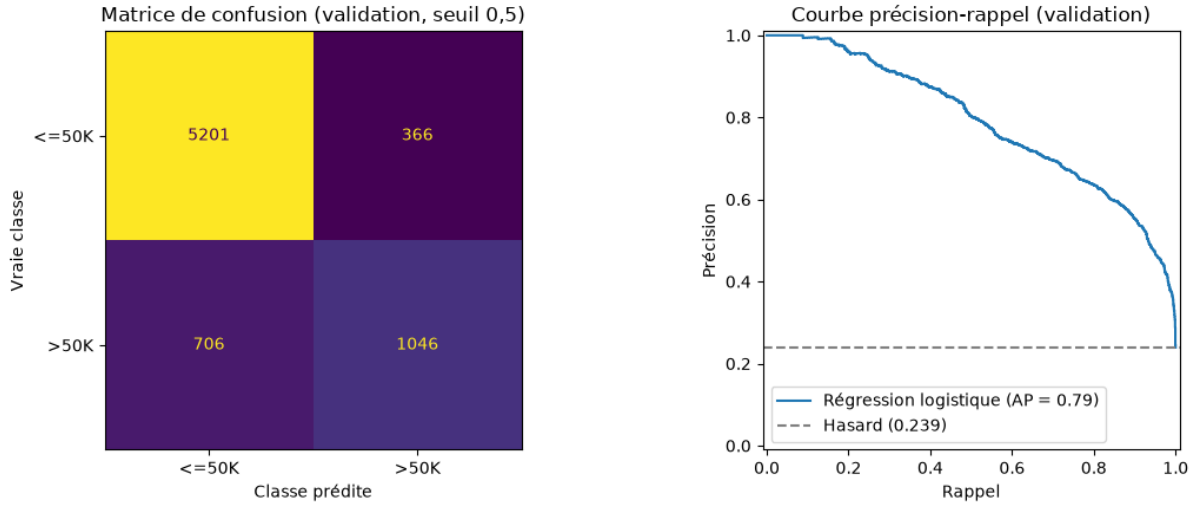


Figure 2 – Modèle de référence sur la validation : matrice de confusion au seuil de 0,5 et courbe précision-rappel.

Nous avons comparé les trois remèdes du cours, du moins au plus invasif : **ajuster le seuil** (change la décision), **pondérer les classes** (`class_weight="balanced"`, change l'apprentissage) et **SMOTE** (change les données d'entraînement, placé dans le Pipeline d'imbalanced-learn pour n'être appliqué qu'au train). Chaque remède

est évalué au seuil de 0,5, puis au seuil donnant 80 % de rappel, seule comparaison équitable pour notre objectif.

Tableau 2 – Comparaison des remèdes au déséquilibre (validation)

Remède	Seuil	PR-AUC	Précision	Rappel	F1	Proba. moyenne	Brier
Référence	0,500	0,788	0,741	0,597	0,661	0,237	0,097
Référence, seuil ajusté	0,305	0,788	**0,636**	0,800	0,709	0,237	**0,097**
Pondération des classes	0,500	0,786	0,589	0,861	0,699	0,362	0,121
Pondération, seuil ajusté	0,581	0,786	0,632	0,800	0,706	0,362	0,121
SMOTE	0,500	0,788	0,594	0,860	0,702	0,356	0,120
SMOTE, seuil ajusté	0,577	0,788	0,632	0,800	0,706	0,356	0,120

La pondération et SMOTE **n'améliorent pas le classement** (PR-AUC inchangée, courbes superposées) : ils élèvent seulement le niveau des probabilités. **À rappel égal, les trois remèdes se valent** (précision de 0,632 à 0,636). En revanche, apprendre dans un monde artificiel à 50/50 **gonfle les probabilités** (0,36 en moyenne pour une vraie part de 0,24) et dégrade le score de Brier. **Nous retenons l'ajustement du seuil**, le plus simple : il atteint l'objectif sans réentraînement ni données artificielles, et garde des probabilités réalistes. C'est cohérent avec un déséquilibre modéré ; avec un déséquilibre extrême (fraude à 0,17 %), la pondération ou SMOTE pourraient devenir utiles. Ce remède est appliqué aux trois modèles de la partie 5.

5. Progression de modélisation, réglage et suivi

5.1 Trois modèles, une progression

Nous comparons trois modèles qui suivent la progression du cours, chacun corrigeant une faiblesse du précédent : la **régression logistique** (simple et interprétable, mais linéaire), le **Random Forest** (une moyenne d'arbres indépendants qui trouvent seuls seuils et interactions) et **LightGBM** (des arbres construits séquentiellement, chacun corrigeant les erreurs des précédents). Les trois reçoivent exactement le même prétraitement, seul l'estimateur change.

Tableau 3 – Modèles avec leurs hyperparamètres par défaut (validation croisée sur le train, puis validation au seuil donnant 80 % de rappel)

Modèle	PR-AUC CV (± écart-type)	PR-AUC validation	ROC-AUC	Précision	F1	Contactés à tort
Régression logistique	0,782 ± 0,006	0,788	0,916	0,636	0,709	802
Random Forest	0,757 ± 0,010	0,753	0,900	0,600	0,687	935
LightGBM	0,830 ± 0,006	0,833	0,932	0,682	0,736	655

LightGBM est nettement le meilleur. **Le Random Forest par défaut fait moins bien que la logistique** : sans limite de profondeur, chaque arbre pousse jusqu'à des feuilles d'une seule personne et apprend le bruit du train (forte variance). La moyenne de 100 arbres ne compense pas entièrement. Sans réglage, un modèle plus puissant n'est donc pas forcément meilleur. Les écarts-types (0,006 à 0,010) sont bien plus faibles que les écarts entre modèles : le classement est fiable.

5.2 Réglage des hyperparamètres avec Optuna

Chaque modèle est réglé avec **Optuna** (échantillonneur TPE, graine fixe) : à chaque essai, le Pipeline complet est évalué par validation croisée à 5 plis stratifiés sur le train, et Optuna utilise ce score pour orienter les essais suivants. Budget : 30 essais pour la logistique (`C`) et le Random Forest (`n_estimators`, `max_depth`,

`min_samples_leaf`, `max_features`), 50 pour LightGBM (`n_estimators`, `learning_rate`, `num_leaves`, `min_child_samples`, `subsample`, `colsample_bytree`, `reg_lambda`), avec une échelle logarithmique pour les hyperparamètres dont l'effet dépend de l'ordre de grandeur. Les espaces de recherche et les hyperparamètres retenus sont détaillés en annexe C. Pour que le score rapporté ne soit pas optimiste, chaque modèle réglé est réentraîné sur tout le train, puis évalué sur la validation, qu'Optuna n'a jamais vue.

Tableau 4 – Avant et après réglage (validation, seuil donnant 80 % de rappel)

Modèle	PR-AUC CV meilleur essai	PR-AUC val. défaut	PR-AUC val. réglé	Précision réglé	Contactés à tort défaut → réglé
Régression logistique	0,784	0,788	0,790	0,634	802 → 809
Random Forest	0,815	0,753	**0,818**	0,660	935 → 723
LightGBM (modèle final)	0,834	0,833	**0,835**	**0,686**	655 → **642**

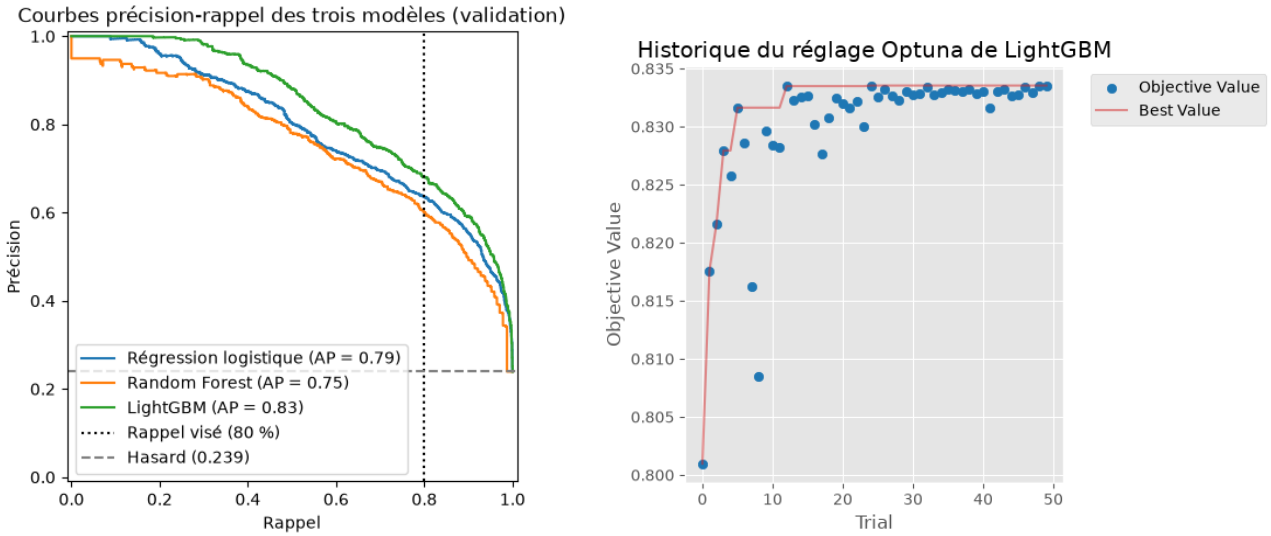


Figure 3 – À gauche : courbes précision-rappel des trois modèles par défaut (validation). À droite : historique du réglage Optuna de LightGBM.

Le **Random Forest** est le grand gagnant du réglage (PR-AUC de 0,753 à 0,818) : Optuna limite la profondeur (`max_depth` = 14) et la part de variables testées (`max_features` = 30 %), corrigeant le surapprentissage. **LightGBM** gagne peu (0,833 à 0,835), ses réglages par défaut étant déjà bons. Optuna choisit plus d'arbres (600) avec des corrections plus petites (`learning_rate` = 0,023). La **logistique** ne gagne rien : le `C` choisi est élevé (31,7), soit une régularisation faible, car avec 34 152 lignes pour 66 colonnes le risque de surapprentissage est faible. **LightGBM réglé est notre modèle final** (seuil de 0,339). Enfin, l'optimisme attendu du meilleur score de validation croisée ne s'observe pas ici : 0,834 contre 0,835 en validation, un écart du même ordre que l'écart-type entre plis. Avec 34 152 lignes et un budget modéré, le biais de sélection reste faible, ce n'était pas garanti, d'où l'intérêt de l'avoir vérifié sur des données non vues. L'historique montre que le meilleur score plafonne après une quinzaine d'essais : un budget plus grand n'apporterait qu'un gain marginal.

5.3 Suivi des expériences avec MLflow

Chaque exécution est enregistrée dans **MLflow** (base locale `mlflow.db`, expérience `census-income`) avec ses paramètres, ses métriques et ses artefacts. Trois familles d'exécutions coexistent : `Optuna - <modèle>`, contenant une exécution enfant par essai (110 au total) avec les hyperparamètres testés et la PR-AUC de validation croisée. `Final - <modèle>`, avec les meilleurs hyperparamètres, les métriques de validation, la courbe précision-rappel et le fichier du Pipeline entraîné. `Défaut - <modèle>`, pour garder la trace du point

de départ. L'évaluation finale sur le test est également enregistrée. Ce suivi permet de retrouver, comparer et recharger n'importe quel essai.

6. Explicabilité et diagnostic du modèle final

6.1 Importance globale (SHAP)

Pour une prédiction, SHAP répartit l'écart entre la prédiction moyenne et celle de la personne entre ses variables (contributions en log-odds pour LightGBM). La moyenne des contributions absolues sur 2 000 personnes de la validation donne l'importance globale. SHAP explique **le comportement du modèle**, pas la réalité : une contribution n'est pas une preuve de causalité.

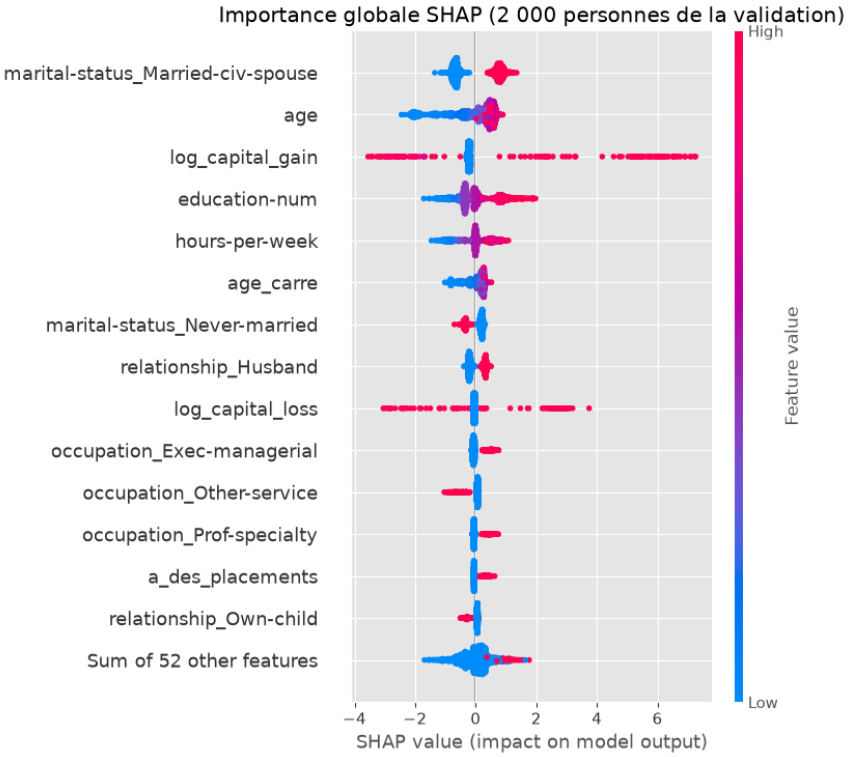


Figure 4 – Importance globale SHAP du LightGBM final (chaque point est une personne ; rouge = valeur élevée).

En regroupant les colonnes one-hot par variable d'origine, l'ordre d'importance est : **`marital-status`** (0,95), age (0,55), `log_capital_gain` (0,55), `education-num` (0,47), `relationship` (0,39), `hours-per-week` (0,34) et `occupation` (0,34). Leur sens métier est cohérent :

- **être marié** pousse fortement vers `>50K`, ne jamais l'avoir été pousse vers `<=50K` : la situation de couple est liée à l'âge et à la stabilité professionnelle ;
- **les plus jeunes** ont des contributions très négatives (début de carrière) ; avec `age_carre`, le modèle reproduit la courbe en cloche ;
- **les gros gains en capital** poussent jusqu'à +6, signe d'un patrimoine ; à l'inverse, les **petits** gains (moins de 5 000) font baisser la prédiction, ce que confirmait l'EDA (18 % de `>50K` dans cette tranche) ;
- **le niveau d'études** et **le temps de travail** élevés poussent vers `>50K`.

Point d'attention : `relationship_Husband` fait partie des variables importantes. Cette modalité désigne presque toujours un homme : c'est le **proxy du sexe** identifié au cadrage. Bien que `sex` ne soit pas une variable du modèle, celui-ci s'appuie en partie sur une information qui le reconstruit (partie 8).

6.2 Explications locales

Nous avons expliqué trois prédictions au seuil final (prédiction moyenne : −2,38 en log-odds, environ 8,5 %) :

- **vrai positif (probabilité 0,999)** : un homme de 54 ans, indépendant, diplômé d'une école professionnelle, marié, avec un gain en capital de 99 999. Le gain explique l'essentiel (+5,8), complété par les études (+1,2) et le mariage (+0,5) ;
- **faux négatif (probabilité quasi nulle)** : un homme de 20 ans, niveau 12th, célibataire, vivant chez ses parents, 35 h par semaine, et pourtant >50K. Tout pousse vers <=50K, l'âge en premier (−1,9). Aucune variable ne permettait de le détecter : profil atypique, voire erreur de saisie de la cible ;
- **faux positif (probabilité 0,923)** : un homme de 33 ans, marié, cadre, 60 h par semaine, avec un gain de 4 386, mais <=50K. Le gain (+1,5), le mariage (+1,0) et les heures (+0,6) ressemblent à ceux des hauts revenus : une erreur peu coûteuse pour la banque, et un client peut-être proche des 50 K$.

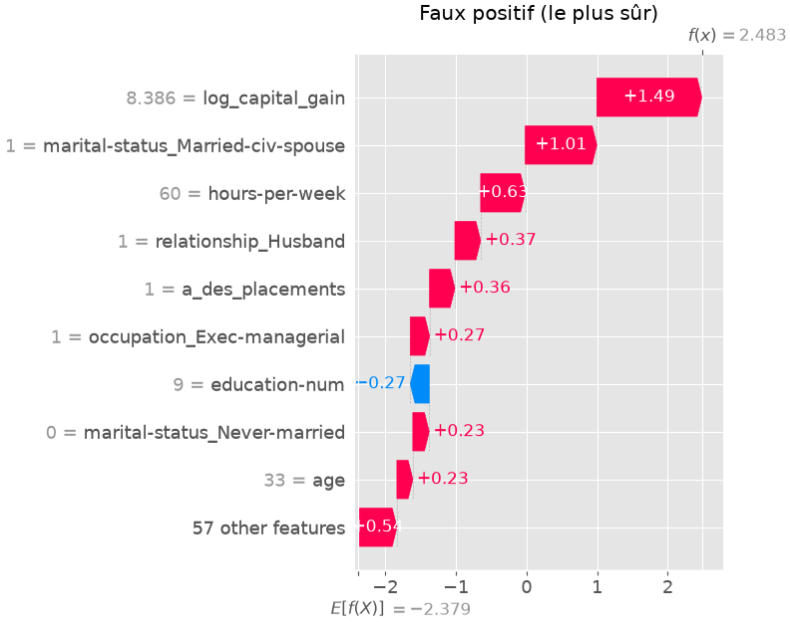


Figure 5 – Explication SHAP locale du faux positif le plus sûr : chaque barre ajoute la contribution d'une variable à la prédiction moyenne.

6.3 Diagnostic par segment

Un bon score global peut cacher un segment où le modèle échoue. Le tableau ci-dessous donne les métriques par tranche d'âge sur la validation, avec l'effectif et la part de positifs (la PR-AUC en dépend fortement). Le segment le plus faible est défini avec la métrique qui compte pour notre cas d'usage, le rappel.

Tableau 5 – Performance du modèle final par tranche d'âge (validation, seuil final)

Âge	Effectif	Dont >50K	Part de >50K	PR-AUC	Précision	Rappel
17-25 ans	1 458	21	0,014	0,502	0,700	0,333
26-35 ans	1 933	368	0,190	0,788	0,679	**0,707**
36-45 ans	1 770	618	0,349	0,841	0,681	0,827
46-55 ans	1 244	487	0,391	0,870	0,694	0,873
56-65 ans	669	207	0,309	0,818	0,674	0,787
66-90 ans	245	51	0,208	0,858	0,766	0,706

Le rappel des 17-25 ans (33 %) repose sur 21 positifs seulement : il est trop incertain pour conclure. **Le segment le plus faible significatif est celui des 26-35 ans** (368 >50K, rappel de 71 % contre 80 % au global) :

des personnes en début de carrière que le modèle juge « trop jeunes ». Par sexe, le rappel est de 77,2 % pour les femmes contre 80,5 % pour les hommes ; par origine, il est plus faible pour les personnes noires (72,9 %, 85 positifs) que pour les personnes blanches (80,4 %), les autres groupes étant trop petits pour conclure (détail en annexe D).

7. Diagnostics de calibration

La PR-AUC mesure si le modèle classe bien. La calibration vérifie si ses probabilités sont justes, quand il annonce 30 %, y a-t-il environ 30 % de >50K ? C'est important si la banque utilise les probabilités elles-mêmes, par exemple pour estimer le nombre de ventes attendues.

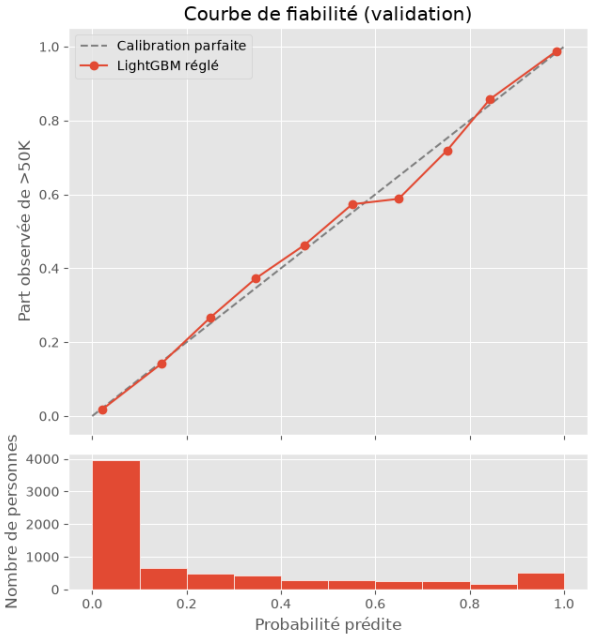


Figure 6 – Courbe de fiabilité du modèle final sur la validation et répartition des probabilités prédites.

Le modèle est bien calibré. Son score de Brier vaut **0,086**, deux fois moins qu'une prédiction constante (0,182), et son **ECE vaut 0,010** : en moyenne, probabilité prédite et part observée ne diffèrent que d'un point. La courbe suit la diagonale, avec deux petites déviations : une **légère sous-confiance** entre 0,2 et 0,6 (par exemple 37,3 % observés pour 34,7 % prédits) et une **légère sur-confiance** entre 0,6 et 0,8 (58,8 % observés pour 64,9 % prédits). Ces tranches comptent moins de 500 personnes ; avec environ 270 personnes, la marge d'erreur est d'environ ±6 points : les écarts sont du même ordre que le bruit. Le détail par tranche figure en annexe D. Les deux tranches extrêmes, les plus peuplées (3 951 personnes sous 0,1 et 514 au-dessus de 0,9), sont les mieux calibrées. Ce résultat est cohérent avec nos choix : LightGBM optimise la *log-loss* et nous n'avons utilisé ni pondération ni SMOTE.

Tableau 6 – Effet d'une recalibration (calibrateurs appris sur des prédictions hors pli du train, évalués sur la validation)

Version	Score de Brier	ECE	PR-AUC
Sans recalibration	0,0862	0,0103	0,8346
Platt (sigmoïde)	0,0862	0,0103	0,8346
Isotonique	0,0863	0,0094	0,8243

Aucune recalibration n'est utile : Platt apprend une correction quasi identique, preuve que les probabilités étaient déjà justes ; l'isotonique réduit à peine l'ECE mais dégrade le Brier et la PR-AUC, sa fonction en escalier regroupant des clients que le modèle distinguait. La calibration reste bonne par sexe (ECE de 0,016), avec une légère surestimation pour les femmes (11,1 % prédits pour 10,2 % observés). **Nous ferions confiance**

aux probabilités telles quelles pour une décision en aval sur cette population, avec trois réserves : à revérifier si la clientèle ou les revenus changent (données de 1994), éviter une précision excessive dans les tranches intermédiaires, et confirmation sur le test (partie 9).

8. Audit d'équité et de biais

8.1 Définition d'équité et audit

L'attribut sensible audité est **sex** (30,4 % des hommes sont `>50K` contre 10,9 % des femmes, groupes de grande taille). La `race` sert de découpage complémentaire, deux de ses groupes étant trop petits. Choisie **avant** de voir les résultats, à partir du coût des erreurs, notre définition prioritaire est **l'égalité des chances** : le même rappel pour les femmes et les hommes. Une femme qui gagne plus de 50 K$ doit avoir autant de chances qu'un homme de recevoir l'offre. Nous rapportons aussi les métriques des autres définitions.

Tableau 7 – Audit d'équité sur la validation (seuil unique de 0,339)

Groupe	Part contactée (parité démographique)	Rappel (égalité des chances)	Taux de faux positifs (égalité des erreurs)	Précision (parité prédictive)
Femmes (2 402, dont 246 >50K)	0,113	0,772	0,038	0,701
Hommes (4 917, dont 1 506 >50K)	0,361	0,805	0,164	0,684
Écart (H − F)	0,248	**0,032**	0,127	−0,018

L'égalité des chances est presque respectée sur la validation (3,2 points d'écart), la parité prédictive aussi. La **parité démographique** est fortement violée (ratio de 0,31, sous le seuil des quatre cinquièmes), mais c'est attendu : seules 10,2 % des femmes sont `>50K` contre 30,6 % des hommes, et l'imposer obligerait à contacter des femmes `<=50K` ou à écarter des hommes `>50K`. L'**égalité des erreurs** est violée : les hommes sont bien plus souvent contactés à tort. Comme les taux de base diffèrent, ces définitions ne peuvent pas être satisfaites toutes à la fois (théorème de Chouldechova et de Kleinberg *et al.*). Les écarts proviennent d'un **biais historique** (les écarts de revenus de 1994) et du **proxy** `relationship`.

8.2 Mitigation et comparaison sur le test

Nous appliquons un **post-traitement** : un **seuil de décision par sexe**, choisi sur la validation pour que chaque groupe atteigne 80 % de rappel (0,29 pour les femmes, 0,34 pour les hommes). Le modèle n'est pas réentraîné. À titre de comparaison, nous appliquons le `ThresholdOptimizer` de Fairlearn avec la contrainte d'égalité des rappels. Les trois versions sont comparées sur le **test resté intact**.

Tableau 8 – Performances et écart d'équité avant et après mitigation (test)

Version	Précision	Rappel	F1	Rappel femmes	Rappel hommes	Écart de rappel
Avant (seuil unique)	0,656	0,794	0,718	0,699	0,810	0,111
Après : seuil par sexe	0,652	0,800	0,718	0,738	0,810	**0,072**
Après : ThresholdOptimizer	0,607	0,858	0,711	0,785	0,871	0,086

Avant mitigation, l'écart de rappel est plus grand sur le test (11,1 points) que sur la validation (3,2 points). Le test ne compte que 256 femmes `>50K` : sur un tel effectif, un rappel a une marge d'erreur d'environ ±5,6 points l'écart réel se situe probablement entre ces deux valeurs. Un audit sur un petit groupe doit donc être accompagné de son incertitude. **Le seuil par sexe réduit l'écart de 11,1 à 7,2 points pour un coût quasi nul** (précision de 0,656 à 0,652, F1 inchangé, rappel global de 80 %). L'écart ne disparaît pas, les seuils ayant été

choisis sur la validation où il était faible. `ThresholdOptimizer` réduit l'écart à 8,6 points mais déplace le point de fonctionnement (rappel de 85,8 %, précision de 0,607), car il optimise l'exactitude équilibrée, et ses décisions sont aléatoires pour certains clients. **Nous retenons le seuil par sexe.** L'audit détaillé de chaque version figure en annexe D.

8.3 Limites

Cette mitigation utilise le sexe **au moment de la décision**, ce qui est une question juridique et éthique : dans certains pays, traiter différemment selon le sexe est interdit, même pour corriger une inégalité. Elle ne traite pas non plus la cause (biais historique et proxy). Une piste serait de retirer `relationship` du modèle et de mesurer le compromis entre performance et équité.

9. Évaluation finale, limites et conclusion

Tableau 9 – Performance du modèle final (LightGBM réglé, seuil 0,339) sur la validation et sur le test

Jeu	PR-AUC	ROC-AUC	Précision	Rappel	F1	Brier	ECE
Validation	0,835	0,932	0,686	0,800	0,739	0,086	0,010
Test	**0,824**	**0,927**	**0,656**	**0,794**	**0,718**	**0,089**	**0,009**

Sur le test, utilisé une seule fois, le modèle final obtient une **PR-AUC de 0,824** (contre 0,239 au hasard), une précision de 65,6 % et un rappel de 79,4 %. La légère baisse par rapport à la validation est attendue, la validation ayant servi à choisir le modèle et le seuil. Le rappel passe juste sous l'objectif de 80 % : un seuil réglé sur un jeu de données n'est qu'une estimation pour un autre. La calibration est confirmée (ECE de 0,009).

Synthèse du modèle (model card). Le modèle final est un LightGBM réglé, entraîné sur 34 152 personnes. Il obtient une PR-AUC de 0,824 sur le test et ses probabilités sont fiables telles quelles. Son segment le plus faible est celui des 26-35 ans, avec un rappel de 71 % sur la validation. L'écart de rappel entre femmes et hommes est de 11,1 points sur le test, et un seuil par sexe le réduit à 7,2 points. Le Pipeline est servi par une API FastAPI (POST /predict) qui renvoie la probabilité et la décision de contact.

Limites. Les données datent de 1994 : 50 K$ de l'époque valent environ le double aujourd'hui, et le marché du travail a changé. Le scénario suppose que la banque connaît le temps de travail et les plus-values de ses clients. Faute d'identifiant de ménage, des conjoints peuvent être répartis entre le train et le test. Enfin, les petits groupes (femmes >50K, minorités) rendent les métriques d'équité instables.

Conclusion : Le cadrage a guidé chaque choix. La PR-AUC et le rappel de 80 % ont orienté le traitement du déséquilibre vers un simple ajustement du seuil. L'audit de fuite a conditionné l'usage des montants en capital. La progression logistique, Random Forest puis LightGBM, a montré qu'un modèle plus puissant ne vaut que s'il est réglé. Le modèle final classe bien, donne des probabilités fiables, et ses écarts d'équité sont mesurés et en partie corrigés. Les pistes d'amélioration sont l'étude du compromis entre performance et équité sans la variable relationship, des intervalles de confiance par bootstrap pour les métriques par groupe, et une revalidation sur des données récentes.

Annexes

A. Dictionnaire des variables

Le jeu de données compte 48 842 lignes (48 790 après suppression des doublons) et 15 colonnes. Le tableau précise, pour chaque variable, son traitement dans le modèle final.

Tableau 10 – Variables du jeu de données et traitement dans le modèle

Variable	Type	Description	Traitement dans le modèle
age	Numérique	Âge (17 à 90 ans)	Standardisé ; complété par age_carre
workclass	Catégorielle (8)	Catégorie d'emploi (privé, public, indépendant…)	Unknown si manquant (5,7 %), one-hot
fnlwgt	Numérique	Poids de sondage du recensement	**Retirée** (pas une caractéristique de la personne)
education	Catégorielle (16)	Diplôme le plus élevé	**Retirée** (redondante avec education-num)
education-num	Numérique	Niveau d'études codé de 1 à 16	Standardisé
marital-status	Catégorielle (7)	Situation matrimoniale	One-hot (modalités rares regroupées)
occupation	Catégorielle (14)	Profession	Unknown si manquant (5,7 %), one-hot
relationship	Catégorielle (6)	Rôle dans le foyer (Husband, Wife, Own-child…)	One-hot ; proxy du sexe
race	Catégorielle (5)	Origine déclarée	**Retirée** du modèle ; diagnostics par groupe
sex	Catégorielle (2)	Sexe	**Retirée** du modèle ; attribut sensible de l'audit
capital-gain	Numérique	Plus-values de l'année (0 à 99 999)	Remplacée par log_capital_gain et a_des_placements
capital-loss	Numérique	Moins-values de l'année (0 à 4 356)	Remplacée par log_capital_loss et a_des_placements
hours-per-week	Numérique	Heures travaillées par semaine (1 à 99)	Standardisé
native-country	Catégorielle (41)	Pays d'origine	Unknown si manquant (1,8 %), one-hot, 20 pays rares regroupés
class	Cible	Revenu annuel <=50K ou >50K	Classe positive : >50K (23,9 %)

B. Analyse exploratoire complémentaire

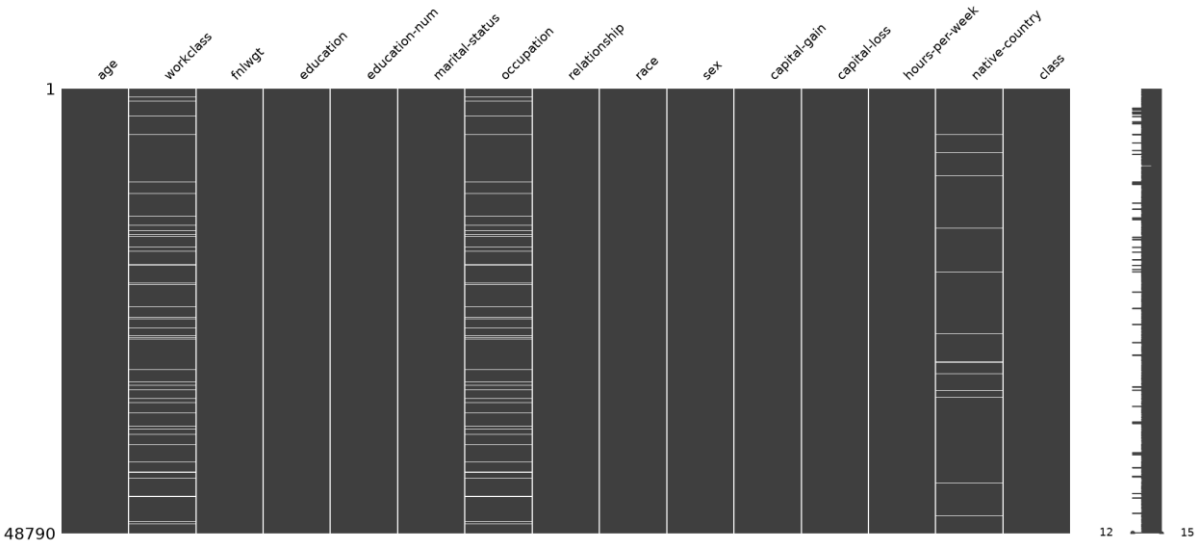


Figure 7 – Carte des valeurs manquantes (traits blancs) : elles ne concernent que workclass, occupation et native-country, et les deux premières manquent sur les mêmes lignes.

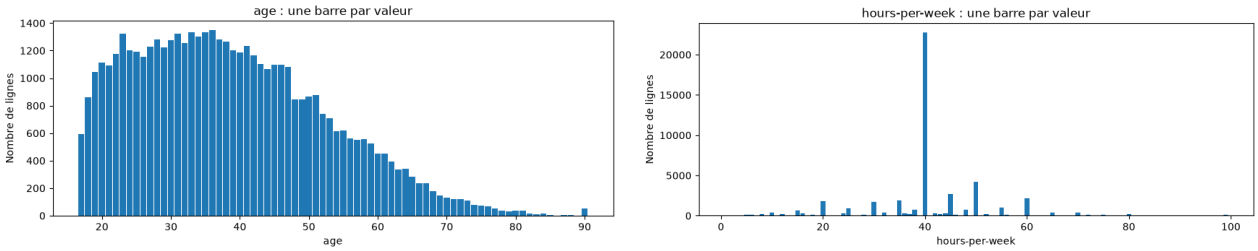


Figure 8 – Distributions de l'âge et du temps de travail hebdomadaire (pic très net à 40 h).

Tableau 11 – Part de >50K selon le montant du gain en capital (jeu complet)

Gain en capital	Effectif	Part de >50K
0	44 755	20,5 %
1 à 5 000	1 584	17,9 %
5 001 à 10 000	1 317	82,9 %
10 001 à 41 310	890	98,0 %
Plafond de 99 999	244	100,0 %

Tableau 12 – Part de >50K selon la situation matrimoniale et le temps de travail (train)

Situation matrimoniale	Effectif	Part de >50K	Heures par semaine	Effectif	Part de >50K
Married-civ-spouse	15 646	44,5 %	1 à 34 h	5 870	7,1 %
Married-AF-spouse	24	37,5 %	35 à 40 h	18 282	20,5 %
Divorced	4 649	10,0 %	41 à 49 h	3 239	34,8 %
Married-spouse-absent	445	9,4 %	50 à 60 h	5 578	44,2 %
Widowed	1 084	9,2 %	61 à 99 h	1 183	36,0 %
Separated	1 061	7,3 %			
Never-married	11 243	4,6 %			

Tableau 13 – Croisement de `relationship` et `sex` : `Husband` et `Wife` désignent presque toujours un homme et une femme

relationship	Femmes	Hommes
Husband	1	19 702
Wife	2 328	3
Not-in-family	5 861	6 696
Own-child	3 370	4 199
Unmarried	3 927	1 197
Other-relative	689	817

C. Réglage des hyperparamètres

Tableau 14 – Espaces de recherche Optuna (échantillonneur TPE, graine 42)

Modèle	Hyperparamètre	Plage explorée	Rôle
Régression logistique (30 essais)	C	0,001 à 100 (log)	Force de la régularisation (petit C = forte pénalité)
Random Forest (30 essais)	n_estimators	100 à 300 (pas de 50)	Nombre d'arbres
	max_depth	4 à 30	Profondeur maximale des arbres
	min_samples_leaf	1 à 50 (log)	Taille minimale d'une feuille
	max_features	sqrt, 0,3, 0,5	Part des variables testées à chaque coupure
LightGBM (50 essais)	n_estimators	100 à 800 (pas de 50)	Nombre de corrections successives
	learning_rate	0,01 à 0,2 (log)	Taille de chaque correction
	num_leaves	15 à 127 (log)	Complexité de chaque arbre
	min_child_samples	10 à 100 (log)	Taille minimale d'une feuille
	subsample	0,6 à 1	Part des lignes utilisées par arbre
	colsample_bytree	0,5 à 1	Part des colonnes utilisées par arbre
	reg_lambda	0,001 à 10 (log)	Régularisation L2 des feuilles

Tableau 15 – Meilleurs hyperparamètres retenus (PR-AUC en validation croisée à 5 plis sur le train)

Modèle	Hyperparamètres	PR-AUC CV
Régression logistique	C = 31,68	0,784
Random Forest	n_estimators = 150 ; max_depth = 14 ; min_samples_leaf = 2 ; max_features = 0,3	0,815
LightGBM	n_estimators = 600 ; learning_rate = 0,0230 ; num_leaves = 32 ; min_child_samples = 10 ; subsample = 0,912 ; colsample_bytree = 0,509 ; reg_lambda = 0,049	0,834

D. Résultats détaillés

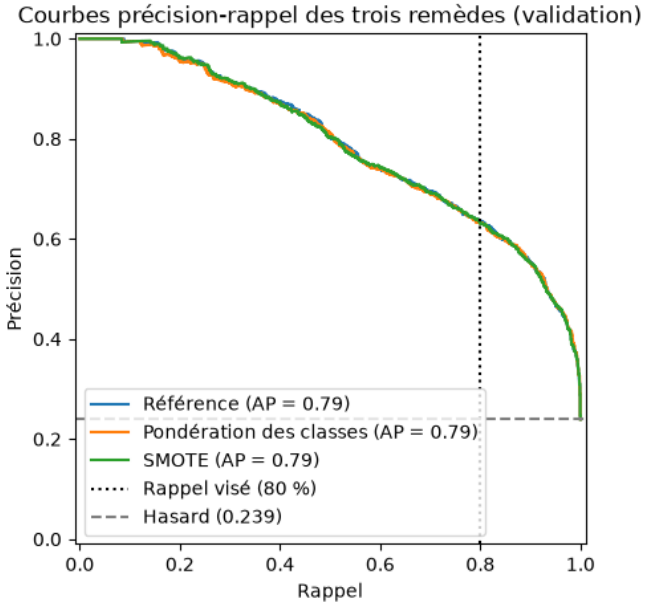


Figure 9 – Courbes précision-rappel des trois remèdes au déséquilibre (validation) : elles se superposent presque, la pondération et SMOTE ne changent pas le classement.

Tableau 16 – Performance du modèle final par sexe et par origine (validation, seuil final)

Groupe	Effectif	Dont >50K	Part de >50K	PR-AUC	Précision	Rappel
Femmes	2 402	246	0,102	0,807	0,701	0,772
Hommes	4 917	1 506	0,306	0,839	0,684	0,805
White	6 240	1 601	0,257	0,838	0,690	0,804
Black	721	85	0,118	0,791	0,674	0,729
Asian-Pac-Islander	231	52	0,225	0,857	0,638	0,846
Other	64	11	0,172	0,691	0,714	0,455
Amer-Indian-Eskimo	63	3	0,048	1,000	0,300	1,000

Les groupes `Other` et `Amer-Indian-Eskimo` comptent moins de 15 personnes `>50K` : leurs métriques varient du tout au tout sur quelques individus et ne permettent aucune conclusion.

Tableau 17 – Calibration par tranche de probabilité (validation)

Tranche de probabilité	Effectif	Probabilité moyenne prédite	Part observée de >50K	Écart
0 - 0,1	3 951	0,022	0,018	−0,004
0,1 - 0,2	665	0,146	0,141	−0,005
0,2 - 0,3	492	0,250	0,266	+0,016
0,3 - 0,4	421	0,347	0,373	+0,026
0,4 - 0,5	294	0,449	0,463	+0,014
0,5 - 0,6	279	0,551	0,573	+0,022
0,6 - 0,7	267	0,649	0,588	−0,061
0,7 - 0,8	267	0,752	0,719	−0,033
0,8 - 0,9	169	0,843	0,858	+0,015
0,9 - 1	514	0,984	0,988	+0,004

Tableau 18 – Audit d'équité détaillé sur le test, avant et après mitigation

Version	Groupe	Part contactée	Rappel	Taux de faux positifs	Précision
Avant (seuil unique)	Femmes	0,121	0,699	0,052	0,613
	Hommes	0,373	0,810	0,181	0,663
	Écart (H - F)	0,251	0,111	0,128	0,050
Seuil par sexe (retenu)	Femmes	0,135	0,738	0,064	0,580
	Hommes	0,372	0,810	0,179	0,665
	Écart (H - F)	0,236	0,072	0,116	0,085
ThresholdOptimizer	Femmes	0,162	0,785	0,088	0,514
	Hommes	0,425	0,871	0,230	0,625
	Écart (H - F)	0,263	0,086	0,141	0,111

La mitigation par seuil par sexe améliore l'égalité des chances (écart de rappel de 11,1 à 7,2 points) mais dégrade légèrement la parité prédictive (écart de précision de 5,0 à 8,5 points) : c'est une illustration concrète de l'incompatibilité entre définitions d'équité lorsque les taux de base diffèrent.

E. Explicabilité complémentaire

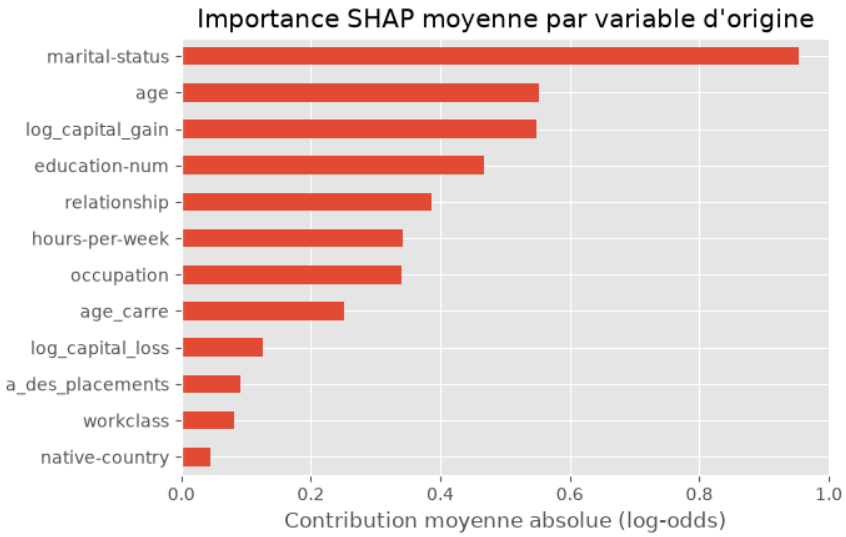


Figure 10 – Importance SHAP moyenne par variable d'origine (contributions des colonnes one-hot additionnées).

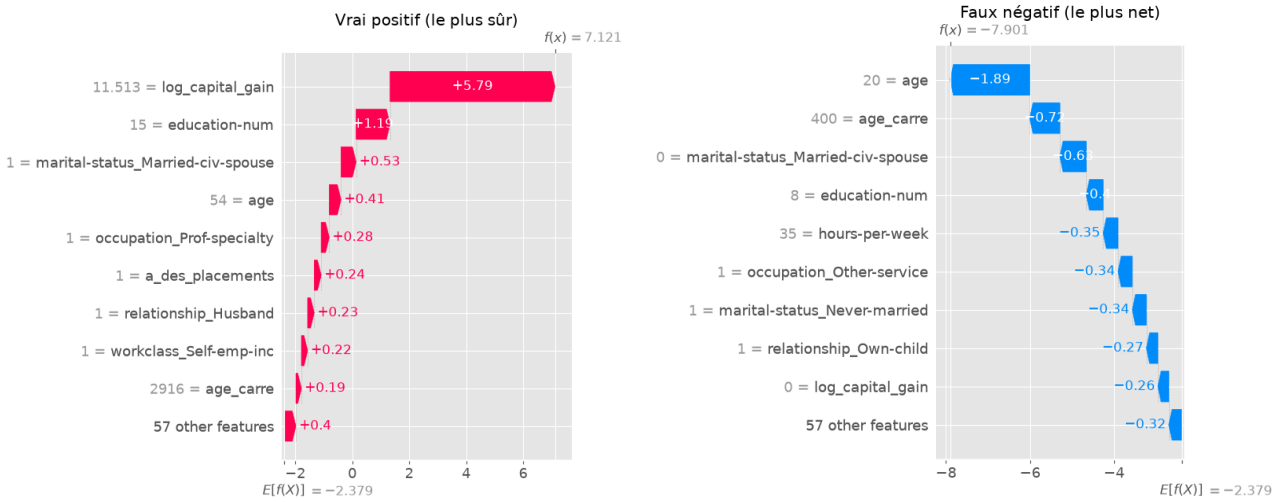


Figure 11 – Explications SHAP locales : à gauche, le vrai positif le plus sûr (gain en capital de 99 999) ; à droite, le faux négatif le plus net (20 ans, Own-child).

F. Glossaire des métriques et des définitions d'équité

Tableau 19 – Métriques utilisées

Métrique	Définition	Lecture
Précision	VP / (VP + FP)	Parmi les clients contactés, part de vrais >50K
Rappel (taux de vrais positifs)	VP / (VP + FN)	Parmi les vrais >50K, part contactée
F1	Moyenne harmonique de la précision et du rappel	Compromis entre les deux
Taux de faux positifs	FP / (FP + VN)	Parmi les <=50K, part contactée à tort
PR-AUC (average precision)	Aire sous la courbe précision-rappel	Qualité du classement des >50K ; hasard = part de positifs (0,239)
ROC-AUC	Aire sous la courbe taux de vrais positifs / taux de faux positifs	Probabilité de classer un >50K au-dessus d'un <=50K ; hasard = 0,5
Score de Brier	Moyenne de (probabilité − réalité)²	Qualité globale des probabilités ; plus bas = mieux
ECE	Écart moyen, pondéré par tranche, entre probabilité moyenne et part observée	Erreur de calibration ; plus bas = mieux

Tableau 20 – Définitions d'équité (groupes : femmes et hommes)

Définition	Ce qui doit être égal entre les groupes	Statut dans le projet
Parité démographique	La part de personnes contactées	Non retenue : ignore la vraie classe
Égalité des chances	Le rappel	**Retenue** : une femme >50K doit avoir autant de chances qu'un homme >50K d'être contactée
Égalité des erreurs (equalized odds)	Le rappel et le taux de faux positifs	Mesurée, non imposée
Parité prédictive	La précision	Mesurée : protège l'efficacité de la campagne plutôt que les clients

G. Organisation du code, reproduction et API

Le rendu se trouve dans le dossier `Rendu_final/` du dépôt. Le notebook `notebook_de_travail.ipynb` retrace toute la démarche et ses justifications ; l'implémentation de référence est dans `src/` et reproduit exactement les résultats du notebook (mêmes hyperparamètres, mêmes métriques).

Tableau 21 – Organisation du code

Fichier	Rôle
`src/config.py`	Chemins, colonnes, graine, seuil de rappel, budgets Optuna
`src/data.py`	Chargement, suppression des doublons, découpage 70 / 15 / 15
`src/features.py`	Nouvelles variables et prétraitement (`ColumnTransformer`)
`src/models.py`	Trois modèles, Pipeline complet, espaces de recherche Optuna
`src/evaluation.py`	Métriques, règle de seuil, ECE, métriques par segment
`src/desequilibre.py`	Exigence 3 : comparaison des remèdes
`src/train.py`	Exigences 4 à 7 : modèles, Optuna, MLflow, sauvegarde du modèle final
`src/explain.py`	Exigence 8 : SHAP et diagnostic par segment
`src/calibration.py`	Exigence 9 : calibration
`src/fairness.py`	Exigence 10 : audit d'équité et mitigation
`src/evaluate.py`	Évaluation finale sur le test
`api/main.py`	API FastAPI (`GET /health`, `POST /predict`)

Reproduction (depuis `Rendu_final/`, Python 3.13) : `pip install -r requirements.txt`, puis `python -m src.train` (environ 10 minutes), `python -m src.explain`, `python -m src.calibration`, `python -m src.fairness` et `python -m src.evaluate`. Les tableaux sont écrits dans `resultats/`, les figures dans `figures/`, les modèles dans `modeles/` et le suivi dans MLflow (`python -m mlflow ui --backend-store-uri sqlite:///mlflow.db`).

API : `uvicorn api.main:app`, documentation interactive sur `/docs`. Exemple de requête `POST /predict` :

```
{"age": 45, "workclass": "Private", "education-num": 13, "marital-status": "Married-civ-spouse", "occupation": "Exec-managerial", "relationship": "Husband", "capital-gain": 0, "capital-loss": 0, "hours-per-week": 50, "native-country": "United-States"}
```

La réponse contient la probabilité d'être `>50K`, la décision de contact et le seuil utilisé. Les entrées sont validées (un âge hors bornes renvoie une erreur 422) ; une modalité inconnue ou un champ absent sont acceptés et traités comme une modalité rare ou `Unknown`.

H. Déclaration d'utilisation d'un assistant de code IA

[À relire et adapter par le groupe.] Nous avons utilisé l'assistant de code **Claude** (Anthropic), via Claude Code, tout au long du projet : explications des notions du cours (métriques, validation, calibration, équité), propositions de code pour le notebook, que nous avons relues, exécutées et vérifiées, conversion du notebook en scripts Python et en API FastAPI, et aide à la rédaction de ce rapport. Les choix de cadrage (cas d'usage, variables conservées ou retirées, métrique, règle de seuil, définition d'équité) ont été discutés et validés par le groupe à chaque étape.

I. Déclaration de l'utilisation de l'IA

Ci-dessous sont présentés tout les point de l'utilisation d'IA par le groupe durant la réalisation du projet :

- Compréhension approfondie de la DataSet ;
- Proposition de traitement de la donnée (exemple : équation de Mincer et $\log(1 + X^i_{\text{capital_gain } ou \text{ _loss}})$) ;
- Amélioration du code réalisé + aide à la rédaction de code (exemple : Cross-Validation) ;
- Compréhension et à l'interprétation des outputs ;
- Aide à la création du Pipline ;
- Bascule du notebook (.ipynb) vers les fichiers python (.py) ;
- Rédaction du rapport final à partir du code et des justifications de notbook et du plan donné.